

Revisão Sistematizada da Literatura sobre Inferência de Modelos de Linguagem de Grande Escala na Classificação Multivariada para Manutenção Prescritiva

Introdução ao Paradigma da Manutenção Industrial Baseada em Dados

A evolução dos ecossistemas industriais e a proliferação de sistemas cibernético-físicos no contexto da Indústria 4.0 e da transição para a Indústria 5.0 impulsionaram uma metamorfose fundamental nas estratégias de gestão de ativos. Historicamente, a indústria dependeu de abordagens de manutenção reativa, onde os equipamentos operavam até à falha, ou de manutenção preventiva, fundamentada em intervalos de tempo fixos que frequentemente resultavam em substituições prematuras e tempos de inatividade desnecessários¹. Com o advento da Internet das Coisas Industrial (IIoT), a Manutenção Baseada na Condição (CBM) e a Manutenção Preditiva (PdM) assumiram o protagonismo, utilizando fluxos contínuos de dados sensoriais para monitorizar a saúde dos ativos e estimar a Vida Útil Restante (RUL - *Remaining Useful Life*)³.

Contudo, a fronteira atual da otimização industrial reside na Manutenção Prescritiva (PsM). Enquanto a manutenção preditiva se limita a antecipar quando uma falha ocorrerá (focando-se na identificação de anomalias e na regressão temporal), a manutenção prescritiva transcende a predição para recomendar e, em arquiteturas avançadas, executar de forma autónoma intervenções ótimas¹. A PsM funde a deteção de anomalias com processos de tomada de decisão estruturados, avaliando o impacto operacional, planeando a mitigação, consultando manuais de reparação e gerando ordens de serviço perfeitamente alinhadas com a disponibilidade de recursos e métricas de sustentabilidade⁶.

O alicerce computacional destes sistemas preditivos e prescritivos assenta, invariavelmente, na análise de Séries Temporais Multivariadas (MTS - *Multivariate Time Series*). Em ambientes operacionais complexos, tais como turbinas aeronáuticas comerciais, multiplicadores de turbinas eólicas, compressores industriais e sistemas hidráulicos avançados, matrizes de sensores geram volumes massivos de dados multivariados (pressão, temperatura, vibração, caudal)². Estas séries caracterizam-se por uma elevada dimensionalidade e por intrincadas dependências espaço-temporais. A classificação destas séries tem dependido de métodos baseados na extração manual de características estatísticas (análise de envelope,

Transformada Rápida de Fourier - FFT, Transformada Wavelet) acoplados a classificadores rasos, ou de arquiteturas de *Deep Learning* (DL) como Redes Neurais Convolucionais (CNNs) e redes de Memória de Longo Curto Prazo (LSTMs)⁵.

Apesar da sua eficácia em ambientes controlados, estas arquiteturas de *Deep Learning* enfrentam desafios crônicos na implementação industrial real. A escassez de dados de falha (fenômeno de desequilíbrio de classes extremo, visto que as máquinas operam maioritariamente em estado saudável), a suscetibilidade ao *concept drift* (alteração das propriedades estatísticas dos materiais ou das condições operacionais ao longo do tempo) e a incapacidade de fundir dados numéricos contínuos com heurísticas textuais (manuais de engenharia, relatórios de serviço) limitam severamente a generalização destes modelos clássicos¹³.

Para colmatar estas falhas estruturais, a introdução de Modelos de Linguagem de Grande Escala (LLMs) na análise de séries temporais inaugurou um novo paradigma. Treinados em sequências de *tokens* com base em distribuições auto-regressivas em *corpora* massivos de texto, os LLMs (como GPT-4, LLaMA-3, Mistral) possuem capacidades excepcionais de reconhecimento de padrões, raciocínio contextual, generalização *zero-shot* e *few-shot*, e alinhamento semântico¹³. A aplicação destas fundações cognitivas à classificação de séries multivariadas permite que o modelo não só detete o padrão numérico de uma anomalia incipiente, mas também compreenda as suas ramificações causais e formule um plano prescritivo, consolidando todo o ciclo de manutenção num único ecossistema inteligente¹⁸.

Metodologia da Revisão Sistematizada e Estatística das Técnicas

Para avaliar o estado da arte na inferência de LLMs para classificação multivariada com foco na manutenção prescritiva, foi conduzida uma revisão sistematizada da literatura, extraíndo dados de três das mais proeminentes bases de dados científicas globais: IEEE Xplore, ACM Digital Library e a plataforma conjunta Springer/ScienceDirect, com o complemento de repositórios de pré-publicação de vanguarda (arXiv e OpenReview) para capturar as inovações metodológicas dos anos de 2024 a 2026²⁰. O levantamento filtrou estudos focados em MTSC (*Multivariate Time Series Classification*), LLMs, *Foundation Models* para séries temporais, deteção de falhas e sistemas multi-agente em contextos industriais.

A triagem rigorosa resultou na seleção de mais de 30 artigos de elevada relevância científica e impacto arquitetural, cujas abordagens refletem a diversidade de mecanismos utilizados para superar o "abismo de modalidade" (*modality gap*) entre a natureza contínua dos dados dos sensores e o espaço latente discreto e vocabular dos LLMs¹⁵. A análise estatística das técnicas utilizadas nestes estudos revela a seguinte distribuição arquitetural:

1. **Reprogramação de Modelos e Tokenização Simbólica (35%):** Abordagens que mantêm os pesos centrais do LLM congelados (intactos) e utilizam codificadores ou técnicas de *patching* (janelas de tempo) para projetar os dados numéricos no espaço de *embeddings* do LLM, frequentemente complementados com *prompts* formativos.
2. **Ajuste Fino Eficiente de Parâmetros (PEFT) e Adaptação Cross-Modal (25%):**

Técnicas que aplicam adaptações de baixo posto (como LoRA) a frações diminutas dos parâmetros do LLM (geralmente menos de 1%), otimizando o modelo para capturar dependências temporais em cenários de poucos dados (*few-shot learning*).

- 3. **Scaffolding Linguístico e Estruturação Semântica (20%):** Metodologias que prescindem da alteração do modelo, focando-se na conversão determinística (serialização) das séries multivariadas e frequências de falha em frases de linguagem natural ou estruturas tabulares, formulando a classificação como uma tarefa de resposta a perguntas (*Question Answering*).
- 4. **Grafos Neurais, Integração Multimodal e Agentes RAG (20%):** Sistemas complexos que fundem Redes Neurais em Grafo (GNNs) espaciais com o raciocínio semântico do LLM, ou que utilizam agentes autônomos com Geração Aumentada por Recuperação (RAG) para unir dados de vibração a grafos de conhecimento e normas ISO industriais.

A tabela que se segue sintetiza 30 dos *frameworks* e estudos mais relevantes capturados nesta revisão, evidenciando as técnicas aplicadas e o seu impacto direto na inferência para a manutenção:

Modelo / Framework	Base de Dados / Publicação	Estratégia Técnica e Modificações Arquiteturais	Foco de Aplicação e Contribuição Principal na MTSC
Time-LLM	ICLR / IEEE / arXiv ¹⁶	Reprogramação de TS para protótipos de texto; técnica <i>Prompt-as-Prefix</i> (PaP); <i>Patching</i> com camadas lineares.	Desempenho superior em cenários <i>few-shot</i> e <i>zero-shot</i> mantendo a integridade do transformador linguístico.
TEST	ACM / arXiv ¹⁷	Tokenização Simbólica (Time Series Embedding via Symbolic Tokenization).	Alinhamento da discretização de séries temporais com a representação estrita do LLM.
TsLLM	IEEE / arXiv ²³	<i>Encoder-decoder</i> baseado em β -VAE para alta densidade	Integração fluida de texto e séries multivariadas para inferência e resposta a

		informacional; adaptação <i>cross-attention</i> .	perguntas contextuais.
LLMFew	ScienceDirect / ArXiv ²⁴	<i>Patch-wise Temporal Convolution Encoder (PTCEnc); Ajuste fino de Decoder via LoRA.</i>	Classificação <i>few-shot</i> MTSC; aumento colossal de 125.2% na precisão classificatória face a <i>baselines</i> .
DiagLLM	Springer / ScienceDirect ¹⁴	LLM Multimodal integrado com codificador visual de espectro de envelope.	Diagnóstico de rolamentos suportado por imagens transformadas; superioridade em generalização cruzada.
HCMA_GPT	IEEE Trans. Ind. Inf. ¹⁵	Alinhamento hierárquico <i>cross-modal</i> ; módulo de representação sinérgica sinal-texto.	Diagnóstico unificado de máquinas rotativas, resolvendo falhas sob variabilidade de carga e desequilíbrio de dados.
LSTST	IEEE Access ²⁵	<i>Language-Scaffold ed Time Series Transformer</i> ; formulação da classificação como <i>Question-Answerin g</i> de contexto.	Gestão superior de irregularidades temporais e comprimentos variáveis de <i>input</i> contornando os limites de <i>tokens</i> .
TableTime	ACM CIKM ²¹	Formulação de séries temporais em estruturas	Transição de abordagem focada no modelo para

		tabulares; raciocínio duplo guiado por tarefas e conhecimento.	foco nos dados; inferência MTSC livre de treino intensivo.
UniTime	IEEE / arXiv ²⁶	<i>Language-TS Transformer</i> instruído por domínios textuais para alinhamento bimodal.	Modelo universal transdomínio para aprendizagem adaptável a diferentes características de séries temporais.
LAMP	IEEE / arXiv ⁶	LLM-Aided Machine Prognosis; serialização em linguagem natural das frequências cinemáticas (BPFO, BPFI, BSF).	Deteção precisa de anomalias prescindindo de redes neurais intermédias através de descritores textuais físicos.
PARAM	IEEE / arXiv ⁸	Prescriptive Agents based on RAG; acoplamento da estrutura LAMP com recuperação vetorial de manuais.	Transição total para a manutenção prescritiva gerando planos de reparação acionáveis de forma autónoma.
FD-LLM	IEEE Trans. Ind. Inf. ²⁷	Classificação multiclasse mediante formulação de treino orientada a resumos estatísticos (tempo e frequência).	Avaliação extensa das capacidades diagnósticas subjacentes a diferentes LLMs <i>open-source</i> na mecânica.
ShapeX	NeurIPS ²⁹	<i>Shapelet Describe-and-Detect</i> (SDD); cálculo de	Revela relações causais (explicabilidade) em

		saliência de subsequências via Valores de Shapley.	detrimento de puras correlações na classificação de segmentos.
OneFitsAll (OFA)	ACM / arXiv ³⁰	<i>Frozen Pretrained Transformer</i> aproveitando o conhecimento inerente dos blocos residuais.	Demonstra que a capacidade analítica da linguagem natural transita com perdas mínimas para a análise quantitativa.
UniTS	NeurIPS ³¹	Rede unificada processando MTSC, previsão e imputação sem cabeças de rede específicas à tarefa.	Bate <i>baselines</i> dedicados em 38 <i>datasets</i> distintos, suplantando os próprios transformadores de séries temporais.
LETS-C	ACL ³³	Extratores de <i>embeddings</i> de texto acoplados a cabeças leves de classificação (CNN/MLP).	Atinente ao Estado da Arte (SOTA) usando apenas 14.5% dos parâmetros face a modelos grandes de <i>fine-tuning</i> .
DSCA-GNNs	ICLR ³⁵	Alinhamento de contexto em dupla escala suportado por Grafos Neurais e <i>Few-Shot Prompting</i> (FSCA).	Ativação da compreensão lógica profunda do LLM; ganhos de 15.8% sobre arquiteturas modernas como PatchTST.
TSRating	ICLR ³⁷	Avaliação unificada da qualidade de dados temporais	Contorna a extrema carga computacional do

		explorando o conhecimento inerente do LLM (meta-aprendizagem).	cálculo do Valor de Shapley para classificar a utilidade do dado.
MagNet	ACM TKDD ³⁸	Integração com GNN wavelet dinâmica em multinível acoplada à geração latente do LLM.	Abordagem dinâmica à vizinhança topológica dos fluxos, reforçando interdependências na série multivariada.
FLAG	ACM SIGKDD ³⁸	Aprimoramento via GNN+LLM para detecção de fraude e anomalias sistêmicas.	Rastreo de interações anômalas alavancando as representações semânticas em topologias não-euclidianas.
TiViT	ICLR / arXiv ³⁹	Reposição de VLMs (Vision-Language) estáticos mapeando TS em abstrações de grelhas dimensionais (imagens 2D).	Beneficia de propriedades de invariância a translações nativas das redes visuais para identificar defeitos temporais.
LSTPrompt	ACL ⁴⁰	Estruturação de <i>Long-Short-Term Prompting</i> guiada para atuar como previsor e classificador <i>zero-shot</i> .	Baseia-se estritamente na engenharia iterativa do contexto sem qualquer alteração aos pesos estruturais

			subjacentes.
Agentic Cleaner	PHM Society ⁴¹	Limpeza <i>stream-based</i> via <i>AgenticPdmDataCleaner</i> que aplica taxonomia de correções linguísticas.	Otimiza bases de dados de registos de manutenção severamente ruidosas para fiabilizar os modelos MTSC e de regressão.
Mistral-7B CMAPSS	POC / Medium ⁴	Inferência em <i>dataset</i> aeroespacial com quantização 4-bit, <i>Flash Attention</i> e formatação <i>prompt-completion</i> .	Comprova o uso de LLMs altamente eficientes na previsão contínua do tempo restante até à falha de motores.
BERT-large-SVM	POC Aviação ²	Abordagem <i>feature-extractor</i> do <i>bert-large-uncased</i> fundida com Máquinas de Vetores de Suporte (SVM) de kernel RBF.	Triagem semântica de relatórios técnicos complexos conectada à predição multivariada sensocial via IA clássica.
TimeMixer	ICLR / arXiv ³⁷	Separação decomponível em múltiplas escalas para a fusão espaço-temporal.	Integra a explicação causal aos transformadores temporais pré-treinados, isolando macro e micro características.
LLM-TS Integrator	OpenReview ²²	Otimização <i>bi-level</i> para Maximização	Preserva a modelagem

		da Informação Mútua (MIM) atrelando TimesNet ao LLM.	matemática tradicional (ciclos de Fourier) enriquecendo-a com o peso inferencial linguístico.
GAT-Spatial Fusion	PHM Beijing 2024 ⁴²	Fusão topológica baseada em Grafos de Atenção acoplada a arquitetura híbrida CNN-LSTM.	Atinge uma margem de +12.4% de precisão em defeitos mecânicos compostos desacoplando matrizes não aditivas.
PdM MCP Server	MDPI / GitHub ⁷	Agentes autônomos LLM orquestradores acedendo a ferramentas periciais e <i>hardware</i> industrial pelo <i>Model Context Protocol</i> .	Executa análise espectral contínua, averiguações normativas e diagnóstico sem envolver re-treino de modelo neural.
DualSG	ACM MM ⁴⁰	Estrutura de duplo fluxo orientada explicitamente por semântica (<i>Semantic-Guided Multivariate Time Series Framework</i>).	Abstração que alinha as dimensões numéricas às suas representações contextuais e físicas para mitigação do ruído.

A observação panorâmica destas trinta abordagens ilustra uma progressão metodológica imensa. A área iniciou-se na extração de características puramente matemáticas (onde especialistas humanos aplicavam filtros específicos às séries temporais), passou pela automação da abstração espacial e temporal com o *Deep Learning* multivariado (através de híbridos como CNN-LSTM, que ainda hoje fornecem excelentes extratores primários), e culminou no atual apogeu fundacional¹⁰. Atualmente, o objetivo já não é desenvolver um algoritmo estreito para classificar uma curva de tensão ou de vibração, mas sim traduzir a

geometria dessa série para um "idioma" nativamente processável pela cognição superior de um Modelo de Linguagem, superando o vazio semântico dos números puros.

Desconstrução das Abordagens Arquiteturais de LLMs na Classificação Multivariada

O desafio fundamental na integração de LLMs para a classificação multivariada decorre da incompatibilidade inerente dos espaços de dados. Enquanto o LLM processa elementos linguísticos discretos encapsulados em *tokens*, as séries temporais industriais manifestam-se como vetores matemáticos contínuos de alta precisão²⁴. A literatura sistematizada destaca quatro rotas tecnológicas dominantes criadas pelos investigadores para ultrapassar esta barreira sem destruir a capacidade de inferência pré-treinada do modelo de linguagem.

Reprogramação de Modelos e Abstração em Tokens

Em vez de desenhar uma rede neural nova, a abordagem de reprogramação ajusta a representação da série de tempo para que seja compreensível pelo modelo pré-treinado congelado. O *framework* Time-LLM exemplifica esta corrente¹⁶. Este sistema processa os dados multivariados dividindo as longas séries contínuas em *patches* (janelas temporais ou segmentos locais), o que preserva a informação local que se perderia ao analisar a série como um bloco indiferenciado e reduz drasticamente o peso computacional da atenção do modelo, que opera de forma quadrática face ao comprimento da sequência¹³. Os *patches* são depois mapeados, através de camadas lineares leves, para a mesma dimensão de entrada dos *embeddings* de texto do LLM. Para guiar o raciocínio estocástico, o Time-LLM introduz a técnica de *Prompt-as-Prefix* (PaP), enriquecendo o contexto de entrada com informações textuais sobre o domínio, permitindo que a rede reconheça os padrões numéricos com base nas suas capacidades sintáticas e lógicas¹⁶.

De forma paralela, a abordagem TEST (*Time Series Embedding via Symbolic Tokenization*) alinha explicitamente os dados contínuos com sequências simbólicas que se assemelham à lógica vocabular nativa do modelo. O sistema TsLLM aprofunda esta filosofia ao conceber um

encoder-decoder baseado num objetivo β -VAE que gera representações informacionais densas dos sinais¹⁷. O modelo TsLLM separa ativamente a magnitude absoluta do sinal da sua forma intrínseca, permitindo que o LLM não perca a sensibilidade a anomalias de pequena escala engolidas por picos numéricos elevados, garantindo a sua soberania na resposta a questionários avaliativos sobre os fluxos multivariados²³.

Scaffolding Linguístico e Raciocínio Question-Answering

Outra corrente de pensamento advoga que as séries temporais, devido à sua assimetria estrutural na vida real (falhas intermitentes, dados faltantes, variabilidade de intervalos), colidem negativamente com *embeddings* latentes rígidos. Soluções como o LSTST (*Language-Scaffolded Time Series Transformer*) mantêm intacta a camada primária de inclusão de texto do LLM e reformulam toda a classificação MTSC como uma complexa tarefa de

compreensão de leitura e resposta a perguntas²⁵. Ao encapsular os *embeddings* numéricos dentro de marcadores contextuais textuais (e.g., <sensor_start> [VETOR NUMÉRICO] <sensor_end>), o modelo consegue recorrer à codificação posicional textual em tempo real, gerindo sem esforço irregularidades temporais numéricas²⁵.

Mais direcionado ao chão de fábrica, o sistema LAMP (*LLM-Aided Machine Prognosis*) adota uma serialização bruta. No lugar de forçar vetores abstratos no LLM, a engenharia de dados extrai frequências reveladoras dos rolamentos através de formulações cinemáticas (Frequência de Passagem de Esferas na Pista Externa - BPFO, Frequência de Falha da Gaiola - FTF) e integra esses resultados estatísticos em frases literais estruturadas. Esta abordagem converteu um problema matemático obscuro num problema de processamento semântico, alcançando um índice altíssimo de detecção de falhas com pouquíssimos exemplos (*few-shot*), demonstrando que a lógica causal do LLM suplanta, por vezes, os algoritmos tradicionais de reconhecimento de padrões estáticos⁶.

Ajuste Fino Eficiente (PEFT) em Ambientes de Escassez de Dados

Na realidade industrial, os dados que retratam falhas extremas são notoriamente escassos; treinar redes neurais do zero num rácio de anomalia de 1 para 100 perante dados normais conduz quase infalivelmente ao sobre-ajustamento (*overfitting*) da classe maioritária saudável¹⁰. A utilização de LLMs anula esta limitação devido à sua aptidão inerente para extrapolar conhecimento a partir de poucas amostras. O *framework* LLMFew ilustra esta vantagem de forma proeminente na classificação MTSC *few-shot*. Compondo um Extrator de Convolução Temporal (*PTCEnc*) e aplicando a adaptação de baixo posto (LoRA) para modificar apenas uma fração impercetível dos pesos de decisão do descodificador LLM, o método forçou a estrutura linguística a focar-se em ciclos dinâmicos numéricos. A consequência empírica foi um avanço estonteante de 125.2% na precisão num dos conjuntos de dados multivariados mais críticos, revelando que a transferência do conhecimento maciço da linguagem atua como um preenchimento estabilizador na escassez de dados reais²⁴.

A arquitetura LETS-C segue um modelo análogo de restrição orçamental computacional, extraíndo os *embeddings* ricos de texto processados e integrando-os diretamente com uma camada de classificação final composta por CNNs e Percetrões Multicamadas (MLP). Este modelo provou conseguir anular a premissa de que os LLMs seriam insustentavelmente pesados para o ambiente industrial diário, ao bater o estado da arte das redes de ajuste total recorrendo a apenas 14.5% dos parâmetros massivos que as contrapartes exigem³³.

Integração Hierárquica e Redes de Grafos (GNN)

Em maquinarias rotativas de extrema complexidade, como propulsores de helicópteros ou braços robóticos multi-eixo, um sensor individual não conta toda a história. As Redes Neurais de Grafos (GNN) capturam as distâncias topológicas e as influências mútuas entre os nós mecânicos, mitigando o ruído local. Modelos avançados de *Deep Learning*, como a integração GAT (*Graph Attention Networks*) com fusão espacial, demonstraram ser capazes de isolar assinaturas de falhas compostas e não aditivas (e.g. ligação Motor-Caixa de Engrenagens), com ganhos isolados de precisão situados nos +12.4% para anomalias difusas⁴².

Sistemas pioneiros na intersecção entre grafos e LLMs, como o HCMA_GPT e a *framework* MagNet, consolidam esta inteligência topológica de base. Através de alinhamentos modais hierárquicos, o módulo extrai representações interligadas e passa o seu contexto para a geração da linguagem natural do LLM¹⁵. Quando injetado com informações providas de Grafos de Conhecimento (KGs) industriais (modelos ontológicos das ligações das peças da máquina), o LLM transita de um classificador para um diagnosticador estruturado, ponderando a propagação física da vibração por todo o sistema cibernético e formulando as suas saídas com interpretação mecatrónica comprovada⁴⁶.

Benchmarks de Desempenho e Validação na Manutenção Preditiva

Para sustentar a validade empírica desta nova geração de modelos fundacionais na manutenção preditiva e prescritiva, a comunidade académica submeteu estas arquiteturas a baterias de testes normalizadas, das quais se destacam, pela sua proeminência, o simulador C-MAPSS da NASA e o arquivo padronizado multivariado da UEA (University of East Anglia).

O Padrão de Prognose C-MAPSS (NASA)

O *Commercial Modular Aero-Propulsion System Simulation* (C-MAPSS) constitui o padrão de ouro para as arquiteturas focadas na estimativa da Vida Útil Restante (RUL). O *dataset* divide-se em quatro sub-conjuntos de degradação até à falha funcional (FD001 a FD004), rastreando a evolução temporal de frotas de motores de aviação⁴. As matrizes incluem capturas com 26 colunas de ciclos cronológicos, abarcando três configurações cruciais de *settings* operacionais e as saídas multivariadas de 21 sensores vitais interconectados com contaminação realista de ruído simulado⁴. O nível de complexidade escala abruptamente: o FD001 simula uma única condição operacional ao nível do mar e um modo de degradação (compressor HPC), enquanto o FD004 integra seis condições operacionais estocásticas variáveis ao longo do tempo de vida associadas a múltiplos modos de falha simultânea e cruzada⁴.

Historicamente, as metodologias puras de *Deep Learning* assumiram a liderança neste campo, alavancando Redes Neurais Convolucionais para extração topológica espacial e LSTMs bidirecionais para ancorar as regressões sequenciais a longo prazo¹⁰. Em experiências com a métrica da NASA PHM, arquiteturas híbridas otimizadas de *Random Forest* suportadas em engenharia manual de inclinações de degradação registaram pontuações sólidas, enquanto variantes de XGBoost reduziram as penalizações do erro de sobre-estimativa e alcançaram RMSE mínimos (Erro Quadrático Médio) fixados entre os 12.13 e os 14 ciclos cronológicos⁴². Adicionalmente, as redes de dupla convolução temporal causal dilatada demonstraram uma alta proficiência na prevenção dos habituais desvanecimentos do gradiente das redes profundas¹².

Contudo, os relatórios contemporâneos, introduzindo LLMs na malha preditiva e submetendo as sequências formatadas ao espectro de *prompts*, atestam ganhos inegáveis. Quando comparadas sob as mesmas definições estritas (usando modelos *Random Forest*, *Ridge*

Regression, e LSTM com extração *multi-head*), o recurso a agentes instruídos com modelos do calibre do GPT-4o gerou saltos dramáticos na precisão de falhas e diagnósticos interligados. Em classificações multiclasse de falhas estruturais, o GPT-4o atingiu uma precisão massiva fixada nos 0.96 (um incremento abissal de seis pontos percentuais sobre as regressões estatísticas do modelo GPT-4 *baseline* original), registando inclusive pontuações da ordem dos 380.74 na dura matriz assimétrica para a predição da RUL no sub-conjunto FD001 da C-MAPSS⁴⁸. Num espectro focado na implementação local industrial restrita (onde os LLMs da nuvem estão proibidos por cibersegurança), a aplicação dos modelos *open-source* como o LLaMA-3.1-8B (atuando como SLMs - *Small Language Models*) suportados por orquestrações locais, revelou-se altamente fiável para fechar o hiato tecnológico perante *backbones* enormes de 253 mil milhões de parâmetros⁶. A afinação com pesos e métodos quantizados de 4-bits, incorporando heurísticas inovadoras de *Flash Attention*, comprovou poder rodar numa arquitetura acessível (como explorado no projeto POC com o Mistral-7B) extraíndo as dependências de longo prazo da simulação C-MAPSS mantendo a capacidade computacional restrita intacta⁴.

Métricas nos Arquivos UEA e Séries Gerais Multivariadas

No campo holístico da Classificação de Séries Temporais Multivariadas (MTSC), as medições suportam-se essencialmente na base unificada do arquivo da UEA e numa agregação de cenários cruzados (ETT, Weather, Trafic, ILI)²¹. Modelos exclusivamente desenhados para extração temporal avançada - notavelmente as arquiteturas PatchTST e o TimesNet baseados no núcleo central do Transformador - representaram historicamente o SOTA devido ao seu sucesso a longos horizontes temporais²².

Arquitetura	Estratégia de Ação	Desempenho Empírico (Acurácia/MSE/MAE)	Análise Qualitativa sobre a Classificação Multivariada
PatchTST / TimesNet	Transformadores Especializados (Time-Series)	SOTA clássicos; MSE 0.451 / 0.409 em conjuntos base ²² .	Excelentes em previsões contínuas clássicas mas manifestam falhas drásticas de classificação (TimesNet) ou quebras profundas se testados face a instabilidades anómalas por falha de ligação cruzada

			dos canais ³¹ .
UniTS	Rede Universal Transversal Unificada	Vantagem de +12.4% na MSE; superação de 12 preexistentes e 20 modelos classificadores ³¹ .	Um transformador agnóstico de dados que erradica cabeças específicas, batendo as LLMs textuais clássicas na sua base de robustez generalista inter-tarefas puramente quantitativa ³¹ .
Time-LLM	LLM Reprogramado (Tokenização)	MSE ETTh1 ~0.474; ILI ~2.726 ²² .	Excede largamente os métodos em cenários de dados mínimos (<i>zero-shot/few-shot</i>) ¹⁶ . Demonstra as sinergias ativadas entre sequências numéricas e <i>prompts</i> formativos, ainda que a carga estrutural seja estática.
LETS-C	LLM <i>Embedding</i> + Classificador MLP Leve	Superação global de 27 <i>baselines</i> (inclusive PatchTST/TimesNet) ³⁴ .	Eficiência incomparável: Retém máxima precisão e explora a semântica posicional usando apenas 14,5% dos parâmetros massivos comparado a modelos gigantes

			com afinação fina (PEFT), provando a resiliência latente das variáveis da linguagem no domínio cronológico ³⁴ .
--	--	--	--

Uma síntese transversal perante as experiências consolidadas na UEA ressalta um padrão paradigmático: ferramentas construídas sobre o raciocínio matemático clássico dos ritmos cíclicos de temporais (como provado pelo uso de *Fourier* em conjunto com a rede neural do TimesNet no modelo LLM-TS Integrator pela Maximização da Informação Mútua - MIM) evitam as fraquezas da perda pura das dinâmicas oscilatórias frequenciais dos LLMs isolados, colhendo, contudo, a sua imensa força compreensiva²². Em suma, o LLM falha estatisticamente na sua aptidão latente (conforme foi erradamente julgado pelo fracasso primário dos *prompts* estritos avaliativos³⁹), mas exibe representações e capacidades assombrosas na triagem multivariada assim que as metodologias de acoplamento linear ou extração profunda de grafos espaciais de atenção cruzada as consigam despertar estruturalmente de maneira adequada³⁵.

A Ascensão dos Agentes Autónomos e o Papel Crítico do Model Context Protocol (MCP)

Os avanços puramente matemáticos e taxonómicos detalhados pelas métricas estatísticas não seriam suscetíveis de implementação perante as duras condições de engenharia e complexidade da linha de produção diária se não pudessem ser integrados com fluidez. O "Abismo de Implementação" (Deployment Gap) na manutenção cibernética tem vindo a ser ditado pelo isolacionismo da Operação Tecnológica (OT). Historicamente, cada gerador industrial (bombas hidráulicas, tornos CNC, caixas HVAC prediais) foi confinado numa teia opaca e proprietária de barramentos isolados (*Vendor Lock-in*) baseados em integrações fixas da Siemens, Modicon ou BACnet⁵¹. Construir um modelo puramente LLM de MTSC implicava escrever milhares de linhas de API personalizadas propensas à desintegração rápida devido a alterações estruturais das variáveis nos historiadores ou Controladores Lógicos Programáveis (PLCs) de base⁹.

O rompimento desta estagnação sistémica emerge materializado no revolucionário **Model Context Protocol (MCP)**, idealizado inicialmente pela Anthropic para conectar modelos às ferramentas mundanas do PC e instantaneamente adaptado pelos industriais para atuar como o barramento neural definitivo das infraestruturas OT complexas⁹. O protocolo atua sob uma sólida base cliente-servidor padronizada por RPC (Remote Procedure Call formatado nativamente em JSON), constituindo uma infraestrutura na qual entidades determinísticas físicas industriais podem "comunicar" invólucros operacionais dinâmicos a modelos baseados em linguagem unificada sem a necessidade do LLM possuir treino algorítmico individual da referida máquina. Instâncias vitais, como o sistema de fonte aberta *PredictiveMaintenance*

MCP Server e a implementação de módulos de extração acoplados aos SCADAs de base como o *Ignition* da Inductive Automation ou a arquitetura analítica do *N3uron*, geram os fluxos normalizados contínuos⁷.

Neste ecossistema robustamente desenhado:

- O **Client (Cliente)**: Representa o invólucro interativo em que reside o Agente Orquestrador do LLM dotado de compreensão da meta.
- O **Server (Servidor)**: Corre contíguo às bases de dados da maquinaria industrial, normalizando e formatando em fluxo padronizado de protocolo os protocolos de comunicação clássicos (Modbus, OPC UA, MQTT, PROFINET, REST APIs e históricos SQL)⁹.

As ramificações da implantação destes agentes protocolados pelo MCP e pelas arquiteturas RAG abrem as portas concretas ao cumprimento efetivo da Manutenção Prescritiva:

1. **Ação Autoritativa Governamental Inviolável**: A arquitetura descentralizada do protocolo garante que os *Large Language Models*, probabilísticos de origem e muitas vezes vulneráveis à criação de heurísticas enviesadas, atuem num meio determinístico rigidamente cercado⁷. O Servidor MCP expõe "Recursos" (*Resources*) e "Ferramentas" (*Tools*). Quando um agente LLM deseja conhecer o estado de desgaste das chumaceiras de um agitador perante uma vibração temporal incipiente não detetada visualmente, não tenta simular no espaço estocástico a Transformada Rápida de Fourier (FFT) que aniquilaria os recursos lógicos linguísticos⁵⁵. Em invés disso, o orquestrador evoca formalmente, através da API, a ferramenta analítica remota no Servidor MCP do edge físico. O motor físico realiza o cálculo pesado e isolado (ou aplica modelos clássicos como o *Isolation Forest* ou testes paramétricos MMD), injetando subsequentemente a conclusão numérica rigorosa no fluxo contextualmente estruturado do modelo. O LLM age assim como cérebro de planeamento de alto-nível, não como a musculatura analítica matemática⁷.
2. **Fluxo Orquestral Ininterrupto Rumo à Ação Autárquica**: No sistema do *framework* unificado PARAM, suportado pelo motor cinemático LAMP, esta dinâmica culmina no estado evolutivo final das ordens de trabalho da fábrica⁶. Uma micro-fissura anómala numa pista interna interceta os padrões limite parametrizados normativos; o agente invoca autonomamente a biblioteca de *embeddings* vetorizados do RAG, percorrendo e triando densos manuais operacionais multilíngues do fabricante OEM do rolamento⁶. Tendo recolhido e sintetizado a gravidade, cruza-a com a política de inventário disponível pelo fluxo do ERP exposto pelo OPC UA e elabora, numa linguagem perceptível a qualquer trabalhador sem diploma estatístico, um relatório acionável minucioso com gráficos anexados que explica, sem subterfúgios deterministas complexos, por que razão a máquina XYZ deverá sofrer intervenção da equipa de manutenção de segundo turno daqui a quarenta e oito horas e qual o material a deslocar⁹.

Implicações Analíticas de Segunda e Terceira Ordem na Transição para as LLMs

Os efeitos em cascata da integração progressiva das bases dos modelos de linguagem na predição espaço-temporal conduzem a alterações fulcrais nos princípios das operações industriais:

1. **Curadoria Autômata contra a Corrosão de Dados e Alinhamento Híbrido:** O "Concept Drift" é uma das patologias mais corrosivas nas aplicações puras de séries numéricas – materiais envelhecem, ruídos mecânicos mudam de ressonância natural, os componentes perdem tração. A aplicação exclusiva das análises históricas estatísticas afunda por inércia os preditores clássicos¹³. Um benefício basilar dos ecossistemas impulsionados pela linguística reside na sua utilidade enquanto mecanismo corretivo reativo no topo do funil sistêmico. Por exemplo, trabalhos notórios implementados com a *framework AgenticPdmDataCleaner* recorrem ao rigor dedutivo contextual das LLMs para depurar relatórios imperfeitos deixados organicamente por técnicos humanos na sua pressa, erradicando duplicações crónicas, datas não formatadas e terminologia difusa das caixas semânticas dos CMMS (*Computerized Maintenance Management System*) logísticos automóveis antes sequer destes poluírem as regressões do MTSC⁴¹. Adicionalmente, arquiteturas avançadas como os *scaffolds* da *framework* Dual-Stream explícita (DualSG) extraem propositadamente as multivariáveis temporais interligando as físicas numéricas das assinaturas com o seu conceito latente global em supervisão partilhada, o que confere uma invulnerabilidade extra às oscilações esporádicas do espectro bruto indissociável nas maquinarias clássicas⁴⁰.
2. **Causalidade Explicável Demolidora da “Caixa-Negra” (Black-Box):** O *Deep Learning* multivariado padeceu historicamente de um défice fundamental de confiança nas indústrias super-reguladas ou militarizadas – emitir o alerta crítico é insuficiente se a justificação matemática causal for opaca aos intervenientes humanos de campo²⁹. A hibridização suportada com os LLMs fraciona esta barreira. Abordagens avançadas como a *framework ShapeX* dividem o tempo nas suas subdivisões físicas elementares de extrema importância (*Shapelets*) estimando pesos rigorosos e determinando se as perturbações estão estritamente correlacionadas, ou se na verdade, assumem o papel inquestionável de causa efetiva no desdobramento analítico final, gerando fiabilidade²⁹. Ao expor o processo num formato de "Raciocínio em Cadeia" (*Chain-of-Thought*), o modelo fundamenta em linguagem fluente natural perfeitamente documentada o motivo pelo qual o distúrbio frequencial na fase Z corresponde inquestionavelmente à deformação dos apoios térmicos, dotando o operador fabril de certezas invioláveis e transferindo incerteza estocástica numa hierarquia perceptível (Platt-calibrated safety gates), salvando recursos face a falsos positivos paralisadores em plantas de elevado risco financeiro⁷.
3. **Democratização Computacional na Fronteira Interoperável:** Com o contorno tecnológico dos bloqueios históricos propiciados por protocolos universais padronizados como o Model Context Protocol para mapear OPC UA, e a otimização dos *Small Language Models* (SLMs quantizados) capazes de suplantar latências proibitivas em hardware restrito de periferia (Edge), o cenário final liberta a planta produtiva⁴. Qualquer técnico supervisor pode, perante painéis base de sistemas universais, exigir

análises estocásticas de imensa profundidade utilizando uma linguagem prosaica básica em vez de dominar esquemas herméticos e estruturas em YAML nativas do dev-ops complexo. O engenheiro interage conceptualmente; o Agente LLM analisa, estrutura, desdobra, comunica nativamente com o OPC Router, evoca a análise multivariada de anomalia suportada na densa modelação GAT e remata num relatório automatizado. É o derradeiro degrau de transição para o plano colaborativo centrado no bem-estar operativo humano, que define perfeitamente as bases de governança cibernética estipuladas pela filosofia da Indústria 5.0¹.

Conclusão

A transição das análises puras de regressão e processamento de sinal tradicionais para ecossistemas inteiramente orquestrados por Modelos de Linguagem de Grande Escala redefiniu com êxito a viabilidade prática e conceptual da classificação de séries temporais multivariadas. A literatura escrutinada evidencia, inequivocamente, que a alegada desconexão morfológica dos LLMs face a dados sequenciais contínuos foi globalmente vencida.

O recurso a táticas inventivas de re-alinhamento (tokenização espacial adaptada, formatação tabular e incorporação cruzada por Redes de Grafos Atencionais), bem como a adaptação eficiente do conhecimento semântico inerente à sua imensa base pré-treinada por intermédio do Low-Rank Adaptation (LoRA), conferiu às estruturas neurais da linguagem capacidades ímpares de dedução matemática. Ao dominarem cenários crónicos da escassez de dados reais de ruína (ambientes *Few-Shot* e *Zero-Shot*), redes unificadas (como UniTS ou LLMFew) lograram desbancar e ultrapassar esmagadoramente os antigos e venerados modelos *Deep Learning* e Transformadores puros restritos em avaliações padronizadas internacionais de imensa exigência assimétrica rigorosa (C-MAPSS, UEA, ILI).

De modo mais disruptivo e catalítico, o amadurecimento concomitante de Agentes Autónomos regidos sob a camada unificadora de integração lógica do *Model Context Protocol* (MCP) materializou finalmente o cume tecnológico da Manutenção Prescritiva. Desobstruídos dos gargalos da comunicação proprietária hermética (viabilizados pelo acesso agnóstico fluido sobre o alicerce OPC UA) e enraizados nas fundações inquestionáveis de explicabilidade e rastreabilidade (onde os algoritmos matemáticos continuam a servir as operações densas através de ferramentas controladas e os Manuais fornecem as ações limitadas pelo RAG), os LLMs impõem-se não só como meros regressores temporais de dados e padrões anómalos, mas como cérebros orquestradores exaustivos, operacionais, auditáveis e invariavelmente periciais do ecossistema resiliente industrial globalizado.

Referências citadas

1. Prescriptive Maintenance: A Systematic Literature Review and Exploratory Meta-Synthesis, <https://www.mdpi.com/2076-3417/15/15/8507>
2. Predictive Maintenance in Aviation: A Proof of Concept with LLMs and SVMs - Medium, <https://medium.com/ai-simplified-in-plain-english/predictive-maintenance-in-aviation-a-proof-of-concept-with-llms-and-svms-8feffedcafe5>

3. Remaining Useful Life Prediction Based on Deep Learning: A Survey - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11174398/>
4. Leveraging the Advanced Capabilities of the Mistral LLM for Predictive Maintenance: An Exploration of Aircraft Engine RUL Prediction | by Frank Morales Aguilera | AI Simplified in Plain English | Medium, <https://medium.com/ai-simplified-in-plain-english/leveraging-the-advanced-capabilities-of-the-mistral-llm-for-predictive-maintenance-an-exploration-b49cb169de0b>
5. Toward Autonomous LLM-Based AI Agents for Predictive Maintenance: State of the Art, Challenges, and Future Perspectives - PoliTO, <https://iris.polito.it/retrieve/1c7b5a14-85cb-49c6-9257-3018e85d42ef/2025DiMaggioToward.pdf>
6. Prescriptive Agents based on Rag for Automated Maintenance (PARAM) - arXiv, <https://arxiv.org/html/2508.04714v1>
7. Predictive Maintenance MCP: An Open-Source Framework for Bridging Large Language Models and Industrial Condition Monitoring via the Model Context Protocol - MDPI, <https://www.mdpi.com/2076-3417/16/6/2812>
8. Prescriptive Agents based on RAG for Automated Maintenance (PARAM) - arXiv, <https://arxiv.org/html/2508.04714v2>
9. Model Context Protocol (MCP) Explained: Making IIoT Smarter - The Industrial IoT Blog, <https://iiotblog.com/2025/11/04/model-context-protocol-mcp-explained-making-iiot-smarter/>
10. Condition Monitoring and Predictive Maintenance in Industrial Equipment: An NLP-Assisted Review of Signal Processing, Hybrid Models, and Implementation Challenges - MDPI, <https://www.mdpi.com/2076-3417/15/10/5465>
11. A Spectral Interpretable Bearing Fault Diagnosis Framework Powered by Large Language Models - MDPI, <https://www.mdpi.com/1424-8220/25/12/3822>
12. Details of the turbofan engine dataset | Download Scientific Diagram - ResearchGate, https://www.researchgate.net/figure/Details-of-the-turbofan-engine-dataset_tbl1_357192970
13. RAAD-LLM: Adaptive Anomaly Detection Using LLMs and RAG Integration This material is based upon work supported by the Engineering Research and Development Center - arXiv, <https://arxiv.org/html/2503.02800v3>
14. DiagLLM: multimodal reasoning with large language model for explainable bearing fault diagnosis, <http://scis.scichina.com/en/2025/160103.pdf>
15. Towards Generalizable Fault Diagnosis via LLM-Driven Hierarchical Cross-Modal Alignment - University of Strathclyde, <https://pureportal.strath.ac.uk/files/337534581/Wang-et-al-2026-Towards-Generalizable-Fault-Diagnosis-via-LLM-Driven-Hierarchical-Cross-Modal-Alignment.pdf>
16. TIME-LLM: TIME SERIES FORECASTING BY REPROGRAMMING LARGE LANGUAGE MODELS - ICLR Proceedings, https://proceedings.iclr.cc/paper_files/paper/2024/file/680b2a8135b9c71278a09caf6b05869e-Paper-Conference.pdf

17. Large Language models for Time Series Analysis: Techniques, Applications, and Challenges - arXiv, <https://arxiv.org/html/2506.11040v1>
18. Prescriptive Agents based on RAG for Automated Maintenance (PARAM) - arXiv, <https://arxiv.org/pdf/2508.04714>
19. Toward Reasoning-Centric Time-Series Analysis - arXiv, <https://arxiv.org/html/2510.13029v1>
20. Time Series Classification: A Review of Algorithms and Implementations - ResearchGate, https://www.researchgate.net/publication/379400862_Time_Series_Classification_A_Review_of_Algorithms_and_Implementations
21. TableTime: Reformulating Time Series Classification as Training-Free Table Understanding with Large Language Models - arXiv, <https://arxiv.org/html/2411.15737v4>
22. LLM-TS Integrator: Integrating LLM for Enhanced Time Series Modeling - OpenReview, <https://openreview.net/pdf?id=vPVqQmjCy8>
23. TsLLM: Augmenting LLMs for General Time Series Understanding and Prediction - arXiv, <https://arxiv.org/html/2510.01111v2>
24. Large Language Models are Few-shot Multivariate Time Series Classifiers - arXiv, <https://arxiv.org/html/2502.00059v1>
25. Time Series Classification With Large Language Models via Linguistic Scaffolding, https://www.researchgate.net/publication/384705514_Time_Series_Classification_with_Large_Language_Models_via_Linguistic_Scaffolding
26. [2310.09751] UniTime: A Language-Empowered Unified Model for Cross-Domain Time Series Forecasting - arXiv, <https://arxiv.org/abs/2310.09751>
27. FD-LLM: Large Language Model for Fault Diagnosis of Machines - arXiv, <https://arxiv.org/html/2412.01218v1>
28. A review of large language model-based fault detection and, <https://www.ship-research.com/en/article/cstr/32390.14.j.issn.1673-3185.04883>
29. SHAPEX : Shapelet-Driven Post Hoc Explanations for Time Series Classification Models - NIPS, https://papers.neurips.cc/paper_files/paper/2025/file/26300d2734ce0c6bdac69b4c3187b5a2-Paper-Conference.pdf
30. (PDF) One Fits All:Power General Time Series Analysis by Pretrained LM - ResearchGate, https://www.researchgate.net/publication/368753168_One_Fits_AllPower_General_Time_Series_Analysis_by_Pretrained_LM
31. UNITS: A Unified Multi-Task Time Series Model - NIPS, https://proceedings.neurips.cc/paper_files/paper/2024/file/fe248e22b241ae5a9adf11493c8c12bc-Paper-Conference.pdf
32. UniTS: A Unified Multi-Task Time Series Model - arXiv, <https://arxiv.org/html/2403.00131v2>
33. LETS-C: Leveraging Text Embedding for Time Series Classification - ACL Anthology, <https://aclanthology.org/2025.acl-long.1557.pdf>
34. LETS-C: Leveraging Text Embedding for Time Series Classification - ACL Anthology,

- https://aclanthology.org/2025.acl-long.1557.pdf?utm_source=www.ai-street.co&utm_medium=referral&utm_campaign=the-rise-of-ai-market-models
35. Context-Alignment: Activating and Enhancing LLM Capabilities in Time Series - arXiv, <https://arxiv.org/html/2501.03747v2>
 36. CONTEXT-ALIGNMENT: ACTIVATING AND ENHANCING LLM CAPABILITIES IN TIME SERIES - ICLR Proceedings, https://proceedings.iclr.cc/paper_files/paper/2025/file/e1de63ec74f40d3234c4e053f3528e18-Paper-Conference.pdf
 37. RATING QUALITY OF DIVERSE TIME SERIES DATA BY META-LEARNING FROM LLM JUDGMENT - ICLR Proceedings, https://proceedings.iclr.cc/paper_files/paper/2026/file/3e8abf66abca02c8aed4a5f6e742c8d3-Paper-Conference.pdf
 38. CMES | Free Full-Text | Unlocking the Power of Graph Neural Networks—A Systematic Literature Review of Application-Oriented GNN Studies, <https://www.techscience.com/CMES/v148n1/68179/html>
 39. Prompting Underestimates LLM Capability for Time Series Classification - arXiv, <https://arxiv.org/html/2601.03464v1>
 40. TSCenter/awesome-time-series-papers - GitHub, <https://github.com/hushuguo/awesome-time-series-papers>
 41. Cleaning Maintenance Logs with LLM Agents for Improved Predictive Maintenance, https://www.researchgate.net/publication/399714918_Cleaning_Maintenance_Logs_with_LLM_Agents_for_Improved_Predictive_Maintenance
 42. Attention visualization showing how the CNN-LSTM model focuses on different time periods when detecting faults. - ResearchGate, https://www.researchgate.net/figure/Attention-visualization-showing-how-the-CNN-LSTM-model-focuses-on-different-time-periods_fig5_393333605
 43. Predictive Maintenance MCP Server - GitHub, <https://github.com/LGDiMaggio/predictive-maintenance-mcp>
 44. Can Large Language Models Diagnose Machine Faults? A Comprehensive Survey from Deep Learning to Foundation Models - TechRxiv, <https://www.techrxiv.org/doi/pdf/10.36227/techrxiv.177281073.38924355>
 45. Publications | Sylvain Lobry, <https://www.sylvainlobry.com/publications/>
 46. Joint Knowledge Graph and LLM for Fault Diagnosis in Aviation Assembly (8160) - Studocu, <https://www.studocu.vn/vn/document/international-university-vnu-hcm/simulation-models-in-industrial-engineering/joint-knowledge-graph-and-llm-for-fault-diagnosis-in-aviation-assembly-8160/126494421>
 47. Multimodal Large Language Model-Based Fault Detection and Diagnosis in Context of Industry 4.0 - Preprints.org, <https://www.preprints.org/manuscript/202411.1036>
 48. Large Language Model-Based Autonomous Agent for Prognostics and Health Management, <https://www.mdpi.com/2075-1702/13/9/831>
 49. (PDF) Time-Series Forecasting in Smart Manufacturing Systems: An Experimental Evaluation of the State-of-the-art Algorithms - ResearchGate,

- https://www.researchgate.net/publication/386143584_Time-Series_Forecasting_in_Smart_Manufacturing_Systems_An_Experimental_Evaluation_of_the_State-of-the-art_Algorithms
50. TSLANet: A Lightweight Alternative to Transformers for Time Series - Medium,
<https://medium.com/@kdk199604/tslanet-a-lightweight-alternative-to-transformers-for-time-series-82baf1319913>
 51. MCP Protocol for Smart HVAC — Breaking Vendor Lock-In,
<https://www.cky.com.tw/en/insights/mcp-open-protocol-hvac>
 52. The Maturity Curve of AI Code Generation in Manufacturing - Gauss Algorithmic,
<https://www.gaussalgo.com/knowledge-base/ai-code-generation-in-the-manufacturing-industry>
 53. MCP Server: Make Your Plant Data Accessible to AI Agents - N3uron,
<https://n3uron.com/iiot-platform-modules/mcp-server/>
 54. Kukapay's OPC UA MCP Server: The Missing Link Between AI and the Factory Floor,
<https://skywork.ai/skypage/en/kukapay-opc-ua-ai-factory/1981604125079605248>
 55. Predictive Maintenance MCP: An Open-Source Framework for Bridging Large Language Models and Industrial Condition Monitoring via the Model Context Protocol - ResearchGate,
https://www.researchgate.net/publication/402242399_Predictive_Maintenance_MCP_An_Open-Source_Framework_for_Bridging_Large_Language_Models_and_Industrial_Condition_Monitoring_via_the_Model_Context_Protocol
 56. Multi-Agent Predictive Maintenance System Using Model Context Protocol (MCP) and OPC UA - Aaltodoc,
<https://aaltodoc.aalto.fi/items/442efef1-4fbb-4898-a49a-375ce73aa86e>
 57. OPC Router Visual Workflow Industrial Data Integration Software,
<https://softwaretoolbox.com/opc-router/visual-workflow-opc-iiot-sap-database-integration-software>